

PROJET DATA & IA

MOBILITÉ & SÉCURITÉ ROUTIÈRE

Construire un projet data de A à Z et un modèle prédictif

FORMAT	DURÉE CONSEILLÉE	LIVRABLES
Équipe de 4 étudiants	30 heures	Dossier + code + données + dashboard

MISSION

Une agence publique fictive souhaite mieux comprendre les facteurs associés aux accidents corporels de la route et disposer d'un outil capable d'estimer le risque de gravité d'un accident à partir du contexte routier, temporel, météorologique et territorial.

RÈGLE ESSENTIELLE

Aucun dataset prêt à l'emploi ne vous est fourni. La recherche, l'évaluation, la sélection, l'acquisition et la traçabilité des sources de données font partie intégrante du projet et de la note.

Question centrale

« Peut-on expliquer et prédire la gravité des accidents routiers à partir de données ouvertes ? »

1. Contexte et objectif du projet

Vous intervenez comme équipe Data auprès de l'Agence Territoriale Mobilité & Sécurité (ATMS), organisme fictif chargé d'aider une collectivité à prioriser ses actions de prévention routière. L'agence ne possède pas encore de plateforme analytique unifiée : les données existent, mais elles sont dispersées sur plusieurs portails publics, dans différents formats et à différentes granularités.

Votre mission : concevoir une preuve de concept complète, reproductible et documentée, depuis la découverte des données jusqu'à la mise à disposition d'indicateurs et d'un modèle d'intelligence artificielle.

1.1 Questions métier auxquelles votre solution devra répondre

- Quels territoires, périodes, horaires et types de voies concentrent les accidents les plus graves ?
- Existe-t-il une relation entre trafic, météo et gravité des accidents ?
- Quels facteurs semblent les plus associés à la gravité ?
- Peut-on entraîner un modèle supervisé estimant la probabilité qu'un accident soit grave ?
- Comment restituer les résultats à un décideur non technique de manière claire et responsable ?

IMPORTANT - ce projet n'est pas un simple notebook

Votre solution doit montrer un véritable cycle de vie de la donnée : recherche des sources, acquisition automatisable, stockage des données brutes, nettoyage/normalisation, intégration, contrôles qualité, analyse, IA, visualisation et documentation.

1.2 Périmètre géographique

Chaque équipe choisit un territoire français (ville, métropole, département ou zone cohérente) uniquement après une étude de faisabilité des données. Le territoire retenu doit permettre de croiser au minimum des données d'accidents, de trafic et de météo. Le choix doit être justifié dans le dossier.

2. Contraintes de données - ce qui est obligatoire

Vous devez d'abord chercher les données

Commencez sur data.gouv.fr, les portails open data des collectivités, l'INSEE, Météo-France et les catalogues d'API publiques. Les liens fournis plus loin sont des pistes de départ : vous devez identifier vous-mêmes les ressources réellement utilisées, leurs fichiers ou endpoints, leurs licences et leur granularité.

Exigence	Minimum attendu
Sources	Au moins 3 sources distinctes, provenant d'au moins 2 producteurs différents.
Open data	Au moins 1 source doit provenir de data.gouv.fr ou être référencée sur data.gouv.fr .
Acquisition	Au moins 1 source doit être récupérée par un accès automatisable : API REST, endpoint JSON/CSV, téléchargement scripté ou service équivalent.
Historique	Le jeu final doit couvrir une période suffisante pour analyser des évolutions et entraîner un modèle. Justifiez la période retenue.
Stockage	Conserver une zone RAW (brute, non modifiée) et une zone CLEAN/CURATED. Une base SQL ou un moteur analytique est attendu pour la couche structurée.
Traçabilité	Conserver URL, producteur, licence, date d'accès, format, fréquence de mise à jour, identifiants de ressource et règles de transformation.
Qualité	Documenter valeurs manquantes, doublons, incohérences, types, unités, coordonnées, dates et clés de jointure.

Interdit comme approche principale : télécharger un dataset déjà nettoyé sur Kaggle et commencer directement l'analyse. Si Kaggle est utilisé, vous devez retrouver et citer la source primaire publique, puis démontrer votre propre acquisition et préparation des données.

2.1 Catalogue des sources à produire

Avant tout développement important, créez un tableau de sourcing contenant au minimum :

- Nom du jeu de données et producteur
- URL de la page source et URL/endpoint de la ressource utilisée
- Licence et conditions de réutilisation
- Format (CSV, JSON, Parquet, API, GeoJSON, etc.)
- Granularité temporelle et géographique
- Variables utiles envisagées
- Clé(s) de jointure possible(s)
- Volume approximatif
- Problèmes de qualité anticipés
- Méthode d'acquisition et fréquence de mise à jour

3. Sources de départ vérifiées

Les ressources ci-dessous ont été identifiées comme pertinentes pour ce sujet. Elles ne constituent pas un « pack de données ». À vous de sélectionner les fichiers, années, API ou territoires adaptés à votre étude et de vérifier la compatibilité des granularités.

1	Accidents corporels - BAAC - ONISR / Ministère de l'Intérieur Base nationale annuelle des accidents corporels. Source centrale du projet pour les accidents, les lieux, véhicules et usagers. https://www.data.gouv.fr/datasets/bases-de-donnees-annuelles-des-accidents-corporels-de-la-circulation-routiere-annees-de-2005-a-2024
2	Données de trafic routier - AVATAR - Cerema / gestionnaires routiers Plateforme publique agréant des données de trafic de plusieurs gestionnaires. Utile pour rechercher un territoire disposant de mesures de débit/vitesse. https://www.data.gouv.fr/datasets/avatar-plateforme-publique-des-donnees-de-traffic-des-gestionnaires-routiers
3	Historique trafic des capteurs permanents - Paris - Ville de Paris Historique de trafic depuis 2010 jusqu'à A-1, avec données de débit et taux d'occupation sur de nombreux tronçons. Option pratique si vous choisissez Paris. https://www.data.gouv.fr/datasets/comptage-routier-historique-donnees-traffic-issues-des-capteurs-permanents-1
4	Données climatologiques quotidiennes - Météo-France Données contrôlées de stations météorologiques, téléchargeables par département et période. https://www.data.gouv.fr/datasets/donnees-climatologiques-de-base-quotidiennes
5	Populations de référence - INSEE Population par circonscription administrative, utile pour normaliser des indicateurs par population. https://www.data.gouv.fr/datasets/populations-de-reference

API tabulaire data.gouv.fr (beta) - data.gouv.fr

API REST permettant de requêter des ressources tabulaires référencées sur data.gouv.fr et d'obtenir les données en JSON.

<https://www.data.gouv.fr/dataservices/api-tabulaire-data-gouv-fr-beta>

Sources vérifiées pour la préparation de ce sujet : 3 septembre 2026. Les portails évoluent : vérifiez les métadonnées au moment de votre collecte.

4. Travail demandé - projet de A à Z

Étape	Nom	Résultat attendu
PHASE 0	Recherche & faisabilité	Identifier les sources, tester l'accès, comprendre les schémas, vérifier les licences et choisir le territoire.
PHASE 1	Acquisition & stockage RAW	Automatiser le téléchargement/apel API, conserver les données brutes horodatées et journaliser l'ingestion.
PHASE 2	ETL & qualité	Nettoyer, typer, normaliser, dédupliquer, traiter les valeurs manquantes, harmoniser dates et géographie, préparer les clés de jointure.
PHASE 3	Intégration & modèle de données	Construire la couche structurée, documenter le schéma, réaliser les jointures entre accidents, trafic, météo et éventuels enrichissements.
PHASE 4	Analyse & data visualisation	Produire les indicateurs, cartes et graphiques expliquant les phénomènes observés.
PHASE 5	Intelligence artificielle	Créer, évaluer et expliquer un modèle supervisé de prédiction de la gravité.
PHASE 6	Restitution & reproductibilité	Dashboard, rapport, README, procédure d'exécution, limites, recommandations et soutenance.

Chaîne cible minimale

SOURCES OPEN DATA	INGESTION API / script	RAW brut	ETL Python/Pandas	CURATED SQL	IA ML	BI Dashboard
----------------------	---------------------------	-------------	----------------------	----------------	----------	-----------------

5. Architecture, stockage et ETL

Vous êtes libres de choisir vos outils, mais l'architecture doit être cohérente, reproductible et justifiée. Une solution locale bien maîtrisée vaut mieux qu'une architecture cloud complexe non comprise.

Brique	Exemples acceptés
Ingestion	Python requests / urllib, API REST, téléchargement scripté, connecteur open data, etc.
RAW	Arborescence locale versionnée par date, stockage objet S3/MinIO/Azure Blob, ou équivalent.
Transformation	Python + Pandas/Polars/PySpark ; fonctions réutilisables ; contrôles de schéma.
Couche structurée	PostgreSQL, DuckDB, SQLite, BigQuery, Snowflake ou équivalent justifié.

Brique	Exemples acceptés
Orchestration	Script principal obligatoire ; Airflow/Prefect/Dagster facultatif mais valorisé s'il est réellement utile.
Versioning	Git obligatoire pour le code ; ne pas versionner de gros fichiers bruts inutiles dans Git.

5.1 Contrôles qualité minimaux

- Contrôle du nombre de lignes avant/après chaque transformation importante.
- Détection des doublons et justification de leur traitement.
- Profil des valeurs manquantes et stratégie par variable.
- Validation des types, formats de dates, unités et plages de valeurs.
- Contrôle des coordonnées géographiques et du système de projection si nécessaire.
- Contrôle des jointures : taux de match, lignes orphelines, doublons créés par la jointure.
- Journalisation des erreurs ou anomalies importantes.

6. Modèle de données, analyse et visualisation

Votre couche analytique doit permettre de relier les faits d'accident à leur contexte. Vous pouvez adopter un schéma en étoile ou un modèle relationnel normalisé, à condition de justifier les choix et de documenter les clés.

Exemple de logique de modèle - à adapter

Fait_Accident (id_accident, date_heure, gravité_cible, localisation...) relié à Dim_Temps, Dim_Lieu, Dim_Météo, Dim_Trafic et éventuellement Dim_Véhicule. Vous ne devez pas recopier ce modèle sans vérifier la granularité réelle de vos sources.

6.1 Analyse exploratoire obligatoire

- Profil statistique des variables et qualité des données.
- Évolution temporelle des accidents et de leur gravité.
- Analyse par heure, jour de semaine, mois/saison et éventuellement vacances/jours fériés.
- Analyse spatiale : carte, zones chaudes ou distribution par territoire.
- Relation météo - accidents / gravité.
- Relation trafic - accidents / gravité.
- Au moins une analyse normalisée (ex. accidents pour 100 000 habitants ou par niveau de trafic), si les données le permettent.
- Matrice/corrélations ou autre méthode adaptée pour explorer les relations entre variables numériques/catégorielles.

6.2 Dashboard / data visualisation

Réalisez un dashboard dans Power BI, Tableau, Metabase, Looker Studio ou une application Python. Il doit être lisible par un décideur et comporter au minimum :

- 4 KPI synthétiques
- 1 visualisation temporelle
- 1 visualisation géographique
- 2 visualisations de comparaison ou de distribution
- des filtres utiles (période, zone, gravité, météo, type de voie...)
- une page ou zone expliquant les limites et la définition des indicateurs

7. Partie Intelligence Artificielle - obligatoire

Objectif IA

Construire un modèle supervisé qui estime la probabilité qu'un accident soit « grave » à partir des informations disponibles au moment ou autour de l'accident, sans utiliser de variable qui révèle directement le résultat final.

7.1 Définition de la cible

Proposition de cible : au niveau de l'accident, considérer « grave » lorsqu'au moins une victime est tuée ou blessée hospitalisée. Vous pouvez proposer une autre définition, mais elle doit être justifiée et calculée de manière transparente à partir des données BAAC.

7.2 Variables explicatives possibles

Exemples : heure, jour, saison, luminosité, conditions atmosphériques, type de route, environnement urbain/rural, caractéristiques du trafic, pluie/température/vent, caractéristiques agrégées des véhicules. Toute variable doit être disponible sans fuite de cible (« data leakage »).

7.3 Méthode minimale attendue

1. Créer un jeu d'apprentissage et un jeu de test. Un découpage temporel est recommandé lorsque la période le permet.
2. Construire un modèle baseline simple (ex. régression logistique ou arbre peu profond).
3. Tester au moins un second modèle plus performant (Random Forest, Gradient Boosting, XGBoost/LightGBM si disponible, etc.).
4. Traiter correctement les variables catégorielles, valeurs manquantes et déséquilibre de classes.
5. Évaluer avec plusieurs métriques : matrice de confusion, précision, rappel, F1 ; ajouter ROC-AUC ou PR-AUC lorsque pertinent.
6. Comparer les modèles et expliquer le choix final.
7. Présenter l'importance des variables ou une méthode d'explicabilité (feature importance, permutation importance, SHAP si maîtrisé).
8. Analyser les erreurs et les cas où le modèle échoue.

Attention au déséquilibre

Si les accidents graves sont minoritaires, l'accuracy seule peut être trompeuse. Votre choix de métriques doit refléter le coût d'un faux négatif et la distribution réelle des classes.

7.4 Responsabilité, biais et limites

- Le modèle ne doit pas être présenté comme un système capable de prédire précisément « où aura lieu le prochain accident ».
- Distinguez corrélation, association et causalité.
- Identifiez les biais de collecte : tous les événements ne sont pas observés de la même manière et les capteurs de trafic ne couvrent pas tout le territoire.
- Discutez les risques de mauvaise interprétation et les usages acceptables du score de risque.
- Ajoutez une mini « model card » : objectif, données, cible, métriques, limites, population/territoire concerné, date du modèle.

Bonus IA (+ points dans la limite du barème) : prévision du trafic à court terme, détection de clusters de zones à risque, analyse SHAP avancée, ou comparaison de modèles temporels, à condition que le socle obligatoire soit terminé.

8. Organisation de l'équipe - 4 étudiants

Chaque membre est pilote d'un domaine, mais le projet reste collectif. Tous les membres doivent comprendre le pipeline complet et être capables de défendre les choix techniques à l'oral.

Rôle	Pilote	Responsabilités principales
Étudiant A	Sourcing & gouvernance	Recherche des sources, catalogue, licences, documentation API, traçabilité, validation de la faisabilité.
Étudiant B	Data Engineering	Ingestion, stockage RAW, scripts ETL, base de données, qualité, logs, reproductibilité technique.
Étudiant C	Data Science & IA	EDA approfondie, feature engineering, entraînement, évaluation, explicabilité, model card.
Étudiant D	BI & restitution	Modèle analytique côté BI, dashboard, storytelling, cohérence des indicateurs, intégration du dossier et maintenance.

Responsabilité collective

Les rôles ne sont pas des silos. Chaque étudiant doit faire au moins une revue croisée du travail d'un autre membre. Le dépôt Git et le journal de contribution doivent montrer une participation réelle des quatre membres.

8.1 Rituels d'équipe recommandés

- Backlog commun avec tâches et responsables
- Point de synchronisation court à chaque séance
- Pull request ou revue de code avant fusion
- Dictionnaire de données partagé
- Décisions d'architecture consignées dans le README
- Une seule version de référence du dashboard et du rapport

9. Livrables obligatoires

Livrable	Contenu attendu
1. Dossier PDF	20 à 30 pages hors annexes : contexte, sourcing, architecture, ETL, qualité, analyse, IA, dashboard, limites, recommandations.
2. Catalogue des sources	CSV/XLSX ou tableau dans le dépôt avec URLs, licences, formats, dates d'accès, variables et granularités.
3. Code	Scripts/notebooks propres et commentés, organisés par étape. Le projet doit pouvoir être relancé.
4. Données	RAW si taille raisonnable, sinon script de récupération + échantillon ; données CLEAN/CURATED et dictionnaire des champs.
5. Base / schéma	DDL SQL ou fichier base + schéma logique/conceptuel et explication des clés.
6. IA	Notebook/script d'entraînement, métriques, comparaison des modèles, importance des variables et model card.
7. Dashboard	Fichier Power BI/Tableau/Metabase ou application + exports PDF/captures lisibles.
8. README	Installation, dépendances, ordre d'exécution, configuration, sources, architecture et limites.
9. Journal de contribution	Répartition des tâches, contributions Git et courte synthèse par membre.
10. Soutenance	10 minutes de présentation collective + 20 minutes de questions/réponses.

10. Structure conseillée du dossier

01. Résumé exécutif (1 page)
02. Contexte, problématique et questions métier
03. Recherche et sélection des sources de données
04. Choix du territoire et étude de faisabilité
05. Architecture et schéma de flux
06. Ingestion, stockage et stratégie RAW/CURATED
07. ETL, qualité et dictionnaire de données
08. Modèle de données et règles de jointure
09. Analyse exploratoire et visualisations
10. Méthodologie IA, modèles testés et résultats
11. Dashboard et interprétation métier
12. Limites, biais, sécurité/RGPD/licences
13. Recommandations et pistes d'amélioration
14. Annexes techniques

11. Barème d'évaluation - 100 points

Critère	Points	Ce qui sera observé
Recherche des données & gouvernance	15	Qualité du sourcing, pertinence, licences, traçabilité, compréhension des granularités, justification du territoire.
Architecture, ingestion & stockage	15	Pipeline cohérent, acquisition automatisable, séparation RAW/CURATED, base structurée, logs et choix techniques.
ETL & qualité des données	15	Nettoyage, normalisation, jointures, contrôles qualité, dictionnaire de données, gestion des anomalies.
Analyse & data visualisation	15	Pertinence des KPI, qualité des graphiques/cartes, lisibilité du dashboard, interprétation métier.
Intelligence artificielle	20	Cible, features, split, baseline, second modèle, métriques, comparaison, explicabilité, analyse d'erreurs et limites.
Reproductibilité & qualité du code	10	Organisation du dépôt, README, paramétrage, scripts relançables, Git, commentaires utiles.
Dossier, soutenance & travail d'équipe	10	Clarté, argumentation, professionnalisme, maîtrise collective et contribution des 4 membres.

12. Jalons et validation intermédiaire

Jalon	Preuve attendue
Jalon 1 - Data scouting	Catalogue d'au moins 5 sources candidates, test d'accès réussi sur 3 sources, choix provisoire du territoire.
Jalon 2 - Ingestion	Script capable de récupérer/reconstruire les données RAW ; arborescence et conventions de nommage.
Jalon 3 - ETL	Premier dataset intégré, rapport de qualité, clés de jointure et schéma de données.
Jalon 4 - Analyse	Premiers KPI et visualisations ; validation des hypothèses et préparation des features.
Jalon 5 - IA	Baseline + modèle 2, métriques sur test, analyse de l'équilibre des classes.
Jalon 6 - Livraison	Dashboard final, dossier, README, nettoyage du dépôt et répétition de soutenance.

13. Questions auxquelles le jury peut vous confronter

- Pourquoi avez-vous choisi ce territoire et pas un autre ?
- Quelle source a été la plus difficile à intégrer et pourquoi ?
- Comment prouvez-vous que votre jointure n'a pas créé de doublons artificiels ?
- Quelle différence faites-vous entre données brutes, staging et données curated ?
- Que se passe-t-il si l'API ou la structure d'un fichier change ?
- Quelle variable explique le plus votre modèle ? Est-ce une causalité ?
- Pourquoi l'accuracy n'est-elle pas suffisante ici ?
- Quel est le coût d'un faux négatif dans votre cas ?
- Comment éviter une fuite de cible ?
- Votre modèle resterait-il valable dans une autre ville ou dans 3 ans ?
- Quelles limites de couverture ont les capteurs de trafic ?
- Comment vos choix respectent-ils les licences, le RGPD et les principes de minimisation ?

14. Checklist avant remise

- ☐ Nous pouvons reconstruire le projet à partir du README.
- ☐ Nous savons exactement d'où vient chaque donnée et sous quelle licence elle est utilisée.
- ☐ Nous avons conservé les données brutes ou une procédure claire pour les retélécharger.
- ☐ Nos transformations sont codées et non réalisées uniquement manuellement dans Excel.
- ☐ Nous avons mesuré la qualité des données avant et après nettoyage.
- ☐ Nous avons contrôlé les jointures et documenté leur taux de correspondance.
- ☐ Notre dashboard répond à des questions métier identifiables.
- ☐ Notre cible IA et nos features sont clairement définies et sans fuite de cible.
- ☐ Nous comparons au moins deux modèles dont une baseline.
- ☐ Nous utilisons des métriques adaptées au déséquilibre éventuel des classes.
- ☐ Nous expliquons les facteurs importants et les erreurs du modèle.
- ☐ Nous distinguons corrélation et causalité.
- ☐ Nous décrivons clairement les limites du projet.
- ☐ Les quatre membres sont capables d'expliquer l'architecture complète.
- ☐ Le dépôt final ne contient ni secret API, ni mot de passe, ni donnée personnelle inutile.

Critère de réussite

À la fin du projet, votre équipe doit pouvoir répondre à cette phrase en une minute : « Voilà où nous avons trouvé les données, comment nous les avons récupérées et fiabilisées, comment nous les avons reliées, ce que nous avons appris, ce que notre modèle IA sait faire, et surtout ce qu'il ne faut pas lui faire dire. »

FIN DU CAHIER DES CHARGES